

Predicción del Éxito Académico en Educación Superior: Un Enfoque de Aprendizaje Automático

Claudia María López Bombín
Grado en Ingeniería Matemática (IMAT) · Clase B · 2.º Curso
Proyecto Final — Aprendizaje Automático · Comillas ICAI · 2025/2026
claudialbombin@alu.icai.comillas.edu ·
202312774@alu.comillas.edu

Abstract

Se aborda la predicción del éxito académico en educación superior sobre un dataset de 4.424 estudiantes con información demográfica, socioeconómica y de rendimiento semestral. Se desarrollan tres tareas: (1) **clasificación** de la situación final (Abandono/Matriculado/Graduado), donde Gradient Boosting alcanza $F1\text{-macro} = 0,716$ en CV 5-fold; (2) **regresión** de la nota media del 2.º semestre (sin *data leakage*), con $R^2 \approx 0,54$ y $RMSE \approx 0,95$; y (3) **clustering K-Means** ($k = 4$) que identifica cuatro perfiles con tasas de abandono entre el 9% y el 80%. El rendimiento del primer semestre es el predictor dominante en ambas tareas supervisadas; variables socioeconómicas como el estado de pagos y la condición de deudor complementan el perfil de riesgo.

Palabras clave: predicción de abandono académico, gradient boosting, clasificación multiclase, regresión de nota media, clustering K-Means, sistema de alerta temprana, educación superior, data leakage, desbalanceo de clases.

1 Introducción

El abandono estudiantil representa un desafío crítico para las instituciones de educación superior, con consecuencias tanto sociales como económicas. La identificación temprana de estudiantes en riesgo permite intervenciones oportunas y una asignación eficiente de recursos. Si bien trabajos previos han abordado este problema con datos administrativos [1], los estudios multi-tarea que combinan clasificación, regresión y perfilado no supervisado son escasos.


Contribuimos con un análisis sistemático en tres tareas complementarias sobre un dataset público de una universidad portuguesa. Hallazgos principales: (i) el gradient boosting domina la clasificación; (ii) los modelos de ensemble capturan no linealidades entre semestres; (iii) K-Means recupera perfiles interpretables estratificados por riesgo; y (iv) la clase Matriculado es la más difícil de predecir por ambigüedad estructural en la etiqueta.

2 Dataset y Análisis Exploratorio

El dataset contiene **4.424 instancias**, **36 variables** y **sin valores nulos**. Las variables incluyen datos demográficos, contexto socioeconómico (beca, condición de deudor, estado de matrícula), calificaciones

previas y datos de matrícula y notas en dos semestres.

Distribución de clases. La variable objetivo presenta un desbalanceo moderado: Graduado 49,9% (2.209), Abandono 32,1% (1.421), Matriculado 17,9% (794). Esto motiva el uso de F1-macro como métrica principal y `class_weight='balanced'` en los clasificadores.



(a) Distribución de la variable objetivo.

(b) Correlación de Pearson con nota media 2.º sem.

Figure 1: Desbalanceo de clases y correlaciones con el target de regresión. Las variables del 2.º semestre con $r > 0,45$ son *leakage* y se excluyen de la regresión.

Hallazgos principales del EDA. `nota_media_1sem` es el predictor individual más potente ($r = 0,82$). `matricula_al_dia` y `deudor` discriminan fuertemente el abandono. Las becas se asocian con mayor graduación; la modalidad vespertina presenta menor tasa de graduación.

3 Preprocesado y Decisiones Metodológicas

Pipeline. Todo el preprocesado se implementa dentro de un `ColumnTransformer`: `StandardScaler` para numéricas, `OneHotEncoder` para categóricas de alta cardinalidad y codificación 0/1 para binarias. Partición 80/20 estratificada. `RANDOM_STATE = 42`.

Data leakage en regresión. Se excluyen las variables del 2.º semestre contemporáneas al target (`asignaturas_2sem_*`) y la variable objetivo. Incluirlas inflaría el R^2 de forma espuria ($r = 0,76$ entre `asignaturas_2sem_aprobadas` y el target).

4 Tarea 1: Clasificación

Se entrenaron cuatro modelos con CV 5-fold estratificada: Regresión Logística (RL), Árbol de Decisión (AD), Random Forest (RF, 300 árboles) y Gradient Boosting (GB, 200 iter., $lr = 0,05$).




Figure 2: Variables numéricas clave por situación académica. Los graduados tienen medianas más altas en notas del 1.er semestre y asignaturas aprobadas. Los estudiantes que abandonan son sistemáticamente mayores al matricularse.

Table 1: Resultados CV 5-fold para clasificación. **Negrita:** mejor valor por columna.

Modelo	Accuracy	F1-macro	F1-weighted
Regresión Logística	0,755	0,712	0,757
Árbol de Decisión	0,703	0,668	0,718
Random Forest	0,779	0,690	0,756
Gradient Boosting	0,784	0,716	0,783

Análisis. Gradient Boosting es el mejor modelo (F1-macro = 0,716). RL resulta muy competitiva pese a ser lineal. RF obtiene menor F1-macro porque sin pesos balanceados perjudica más a la clase minoritaria. Aplicar `class_weight= 'balanced'` mejora el recall de Matriculado del 37% al 56% con pérdida moderada en Graduado.

5 Tarea 2: Regresión

Se predice `nota_media_2sem` usando solo información previa al segundo semestre. Filtrado a notas mayores que cero: media = 12,73, desv. típ. $\approx 1,4$.

Table 2: Resultados CV 5-fold para regresión.

Modelo	RMSE	MAE	R^2
Ridge	1,063	0,843	0,374
Lasso	1,050	0,831	0,390
Árbol de Decisión	1,025	0,800	0,430
Random Forest	0,970	0,736	0,510
Gradient Boosting	0,946	0,719	0,537




Figure 3: Evaluación en test. La clase Matriculado es la más difícil de predecir en todos los modelos.

Análisis. Los modelos de ensemble superan ampliamente a los lineales ($\Delta R^2 \approx 0,16$), evidenciando relaciones no lineales entre semestres. `nota_media_1sem` domina la importancia ($MDI \approx 0,48$). Con información disponible a mitad de curso se puede predecir el rendimiento del 2.º semestre con antelación suficiente para activar programas de apoyo.

6 Tarea 3: Aprendizaje No Supervisado

Se seleccionaron 15 variables previas al resultado final: perfil de entrada, situación socioeconómica, rendimiento del 1.er semestre y contexto macroeconómico.

Dimensionalidad y elección de k . PCA requiere 8 componentes para el 80% de varianza ($PC1= 17\%$, $PC2= 12,8\%$). El coeficiente de silueta se maximiza en $k = 4$ (score $\approx 0,223$) con descenso abrupto para $k \geq 5$.

Table 3: Caracterización de los 4 clusters. Valores en desviaciones típicas.

Cluster	Perfil	Rasgos principales
0	Transición incierta	Edad +1,66 std, notas medias. 43% abandono, 43% graduado.
1	Rendimiento moderado	Admisión +0,85 std, buen 1.er sem. 54% graduado, 21% abandono.
2	Alto rendimiento	Admisión y cualif. previa altas, sin deudas (+1,72 std). 80% graduado.
3	Alto riesgo	Admisión -1,61 std, 1.er sem. -1,67 std, alta deuda +1,72 std. 80% abandono.

7 Discusión

Factores de riesgo convergentes. Los tres análisis convergen en la misma conclusión: el abandono se asocia a bajo rendimiento inicial, situación económica comprometida y edad de matriculación elevada. El




Figure 4: Importancia de variables en clasificación. Ambas métricas señalan el rendimiento semestral, notas de acceso y estado de pagos como predictores clave.

Cluster 3 concentra estudiantes con todos estos factores simultáneamente (80% abandono), convirtiéndose en el objetivo prioritario de cualquier intervención institucional.

Variables accionables. Emergen dos categorías de intervención. Primera, *apoyo económico*: dirigir programas de ayuda financiera a deudores y estudiantes con matrícula pendiente antes de que el daño académico se acumule. Segunda, *apoyo académico*: tutoring y mentoring intensivos en el primer semestre, abordando directamente el predictor dominante. Ambos ejes son identificables con información disponible a mitad del primer año.


Potencial de alerta temprana. El clasificador ($F1\text{-macro} = 0,716$, $\text{accuracy} \approx 78\%$) y el regresor ($R^2 = 0,54$, $\text{RMSE} = 0,95$) son operativos desde mediados del primer año académico, haciendo factible la detección de riesgo en tiempo real sin necesidad de esperar a los resultados finales. El Cluster 3 proporciona además un mecanismo no supervisado, independiente de etiquetas, para el mismo fin.

Limitaciones. (i) Correlación $\neq$ causalidad: una nota baja puede ser consecuencia de factores externos no recogidos en el dataset. (ii) Dataset de una única institución portuguesa: la generalización a otros contextos educativos requiere validación externa. (iii) Ambigüedad estructural en la etiqueta: la clase Matriculado incluye futuros graduados y futuros abandonos, introduciendo dificultad de predicción irreducible ($\text{recall} \approx 38\%$ en todos los modelos).


8 Conclusiones

Se ha presentado un estudio multi-tarea de aprendizaje automático para la predicción del éxito académico en educación superior, abarcando clasificación, regresión y clustering no supervisado sobre un dataset real de 4.424 estudiantes.

Gradient Boosting supera consistentemente a los modelos competidores en ambas tareas supervisadas, alcanzando $F1\text{-macro} = 0,716$ en clasificación triclase y $R^2 = 0,54$ en regresión de la nota media del 2.º semestre sin data leakage. La nota media del primer semestre ($r = 0,82$) es el predictor dominante en todos los análisis, con indicadores socioeconómicos —condición de deudor y estado de matrícula— como señales de riesgo complementarias y directamente accionables.




(a) Real vs. predicho (GB).




(b) Impacto de la selección de variables en R^2 .

Figure 5: Diagnóstico de regresión. Sin sesgo sistemático en residuos. Añadir el 1.er semestre mejora el R^2 un 169% ($0,20 \rightarrow 0,54$).



(a) Varianza explicada por componentes PCA.



(b) Codo y Silhouette para K-Means.


Figure 6: PCA requiere 8 componentes para el 80% de varianza. Silhouette confirma $k = 4$.

El clustering K-Means ($k = 4$) identifica un perfil de alto riesgo (Cluster 3, 80% abandono) caracterizado por nota de admisión baja, mal rendimiento en el primer semestre y alta carga de deuda. Estas características son directamente abordables mediante programas institucionales. Tanto los modelos supervisados como el no supervisado son desplegables a mitad del primer año, haciendo operativamente factible un sistema de alerta temprana con poder predictivo significativo mucho antes de que se conozcan los resultados finales.


Como trabajo futuro se propone: (i) aprendizaje por transferencia entre instituciones para mejorar la generalización; (ii) modelado temporal de la progresión semestre a semestre; y (iii) auditorías de equidad para garantizar que las intervenciones no generen discriminación indirecta por atributos demográficos.

References

- [1] V. Realinho, J. Machado, L. Baptista y M. Martins. Predicting Student Dropout and Academic Success. *Data*, 7(11):146, 2022.
- [2] L. Breiman. Random Forests. *Machine Learning*, 45:5–32, 2001.
- [3] J. H. Friedman. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [4] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [5] I. T. Jolliffe. *Principal Component Analysis*, 2.^a ed. Springer, 2002.



(a) Perfiles estandarizados de los clusters.



(b) Composición por situación académica.

Figure 7: Cluster 3 (alto riesgo): 80% abandono. Cluster 2 (alto rendimiento): 80% graduado.




Figure 8: Proyección PCA 2D: K-Means (izq.), clustering jerárquico (centro) y situación real (dcha.). Ambos métodos producen particiones muy similares, confirmando la robustez de los clusters.