

Predicción del Éxito Académico en Educación Superior: Un Enfoque de Aprendizaje Automático

Claudia María López Bombín

Grado en Ingeniería Matemática (IMAT) · Clase B · 2.º Curso

Proyecto Final — Aprendizaje Automático · Comillas ICAI · 2025/2026

April 5, 2026

Abstract

Se aborda la predicción del éxito académico en educación superior sobre un dataset de 4 424 estudiantes con información demográfica, socioeconómica y de rendimiento semestral. Se desarrollan tres tareas: (1) **clasificación** de la situación final (Abandono/Matriculado/Graduado), donde Gradient Boosting alcanza $F1\text{-macro} = 0.716$ en CV 5-fold; (2) **regresión** de la nota media del 2.º semestre (sin *data leakage*), con $R^2 \approx 0.54$ y $RMSE \approx 0.95$; y (3) **clustering** K-Means ($k = 4$) que identifica cuatro perfiles con tasas de abandono entre el 9 % y el 80 %. El rendimiento del primer semestre es el predictor dominante en ambas tareas supervisadas; variables socioeconómicas como el estado de pagos y la condición de deudor complementan el perfil de riesgo.

1 EDA y análisis descriptivo

El dataset contiene **4 424 instancias**, **36 variables** y **sin valores nulos**. La variable objetivo presenta un desbalanceo moderado: Graduado 49.9 % (2 209), Abandono 32.1 % (1 421), Matriculado 17.9 % (794), lo que motiva el uso de $F1\text{-macro}$ como métrica principal y `class_weight='balanced'` en los clasificadores.




Figura 1: Desbalanceo de clases y correlaciones con el target de regresión. Las variables del 2.º semestre con $r > 0.45$ son *leakage* y se excluyen de la tarea de regresión.




Figura 2: Variables numéricas clave por situación académica. Los graduados tienen medianas más altas en notas del 1.er semestre y en asignaturas aprobadas. Los estudiantes que abandonan son sistemáticamente mayores al matricularse.

Los principales hallazgos del EDA son: (i) `nota_media_1sem` es el predictor individual más potente ($r = 0.82$ con el target de regresión); (ii) `matricula_al_dia` y `deudor` discriminan fuertemente el abandono; (iii) las becas se asocian con mayor tasa de graduación; (iv) la modalidad vespertina presenta menor tasa de graduación, coherente con el perfil de estudiante que compagina estudios y trabajo.

2 Preprocesado y decisiones metodológicas

Pipeline: estandarización (`StandardScaler`) de variables numéricas, `OneHotEncoder` para categóricas de alta cardinalidad y codificación manual 1/0 para binarias (sí/no). Todo integrado en un `ColumnTransformer` para evitar fugas entre train y test. Partición 80/20 estratificada. Semilla global: `RANDOM_STATE = 42`.

Data leakage en regresión. Se excluyen como predictores las variables del 2.º semestre contemporáneas al target (`asignaturas_2sem_matriculadas`, `_evaluadas`, `_aprobadas`, `_sin_evaluacion`, `_convalidadas`) y la variable objetivo. Incluirlas produciría un modelo sin capacidad predictiva real (la correlación $r = 0.76$ entre `asignaturas_2sem_aprobadas` y el target lo evidencia).

3 Tarea 1: Clasificación


Se entrenaron cuatro modelos: Regresión Logística (LR), Árbol de Decisión (DT), Random Forest (RF, 300 árboles) y Gradient Boosting (GB, 200 iter., `lr = 0.05`). Evaluación por CV 5-fold estratificada.

Tabla 1: Resultados CV 5-fold. **Negrita:** mejor valor por columna.

Modelo	Accuracy	F1-macro	F1-weighted
Logistic Regression	0.755	0.712	0.757
Decision Tree	0.703	0.668	0.718
Random Forest	0.779	0.690	0.756
Gradient Boosting	0.784	0.716	0.783

Gradient Boosting es el mejor modelo (F1-macro = 0.716). LR resulta muy competitiva pese a ser lineal. RF, aunque de mayor capacidad, obtiene menor F1-macro porque sin la penalización de pesos


balanceados perjudica más a la clase minoritaria.



(a) Matrices de confusión (test, 885 inst.).

(b) Efecto de `class_weight='balanced'` (LR).

Figura 3: Evaluación en test. La clase *Matriculado* es la más difícil de predecir en todos los modelos. El balanceo mejora su recall de 37 % a 56 % a costa de una pérdida moderada en Graduado.



(a) MDI — Random Forest.

(b) Permutation Importance — LR.

Figura 4: Importancia de variables en clasificación. Ambas métricas señalan el rendimiento semestral, las notas de acceso y la situación de pagos como predictores clave.


Las variables más relevantes son *asignaturas_1sem_aprobadas*, *nota_media_1sem*, *nota_admision* y *matricula_al_dia*. Las variables del 2.º semestre dominan el MDI, lo que recuerda que para un sistema de alerta temprana deberían excluirse.

4 Tarea 2: Regresión

Se predice *nota_media_2sem* usando solo información previa (perfil de entrada + 1.er semestre). El target, filtrado a notas > 0 , tiene media = 12.73 y std ≈ 1.4 .

Tabla 2: Resultados CV 5-fold para regresión.

Modelo	RMSE	MAE	R^2
Ridge	1.063	0.843	0.374
Lasso	1.050	0.831	0.390
Decision Tree	1.025	0.800	0.430
Random Forest	0.970	0.736	0.510
Gradient Boosting	0.946	0.719	0.537



(a) Real vs. predicho (GB).

(b) MDI — RF Regressor.


(c) Impacto selección vars.

Figura 5: Diagnóstico y análisis de la tarea de regresión. Sin sesgo sistemático en residuos. `nota_media_1sem` domina la importancia (MDI ≈ 0.48). Añadir el 1.er semestre al perfil de entrada mejora el R^2 un 169 % ($0.20 \rightarrow 0.54$).

Los modelos de ensemble superan ampliamente a los lineales ($\Delta R^2 \approx 0.16$), evidenciando relaciones no lineales entre semestres. La implicación práctica más relevante es que con información disponible a mitad de curso se puede predecir el rendimiento del 2.º semestre con suficiente antelación para activar programas de apoyo.

5 Tarea 3: Aprendizaje no supervisado

Se seleccionaron 15 variables previas al resultado final: perfil de entrada, situación socioeconómica, rendimiento del 1.er semestre y contexto macroeconómico. Se excluyen variables del 2.º semestre, objetivo y variables de alta cardinalidad poco interpretables.



(a) Varianza explicada por PCA.

(b) Codo y Silhouette para K-Means.

Figura 6: PCA requiere 8 componentes para el 80 % de varianza (PC1 = 17 %, PC2 = 12.8 %). Silhouette máximo en $k = 4$ (score ≈ 0.223) con descenso abrupto para $k \geq 5$, lo que confirma la elección.




Figura 7: Cluster 3: alto riesgo (80 % abandono, nota de admisión -1.61 std, nota 1.er sem. -1.67 std, alta tasa deudores). Cluster 2: alto rendimiento (80 % graduado).




Figura 8: Proyección PCA 2D: K-Means (izq.), clustering jerárquico (centro) y situación real (dcha.). Ambos métodos producen particiones muy similares, confirmando la robustez de los clusters.

Tabla 3: Caracterización de los 4 clusters. Valores en desv. típicas (std).

Cluster	Perfil	Rasgos principales
0	<i>Transición incierta</i>	Edad elevada ($+1.66$ std), notas medias. 43 % abandono, 43 % graduado.
1	<i>Rendimiento moderado</i>	Admisión alta ($+0.85$ std), buen 1.er sem. 54 % graduado, 21 % abandono.
2	<i>Alto rendimiento</i>	Admisión y cualif. previa altas, sin deudas ($+1.72$ std en matrícula). 80 % graduado.
3	<i>Alto riesgo</i>	Admisión baja (-1.61 std), nota 1.er sem. baja (-1.67 std), alta deuda ($+1.72$ std). 80 % abandono.

6 Interpretación crítica y conclusiones

Factores de riesgo. Los tres análisis convergen: el abandono se asocia a bajo rendimiento inicial, situación económica comprometida y edad de matriculación elevada. El Cluster 3 agrupa a estudiantes con todos estos factores simultáneamente (80 % abandono).

Variables accionables. La institución puede intervenir sobre la situación económica (apoyo a deudores) y sobre el rendimiento del primer semestre mediante *tutoring* intensivo. Un sistema de alerta temprana basado en el Cluster 3 o en la predicción de nota del 2.º semestre sería aplicable ya a mitad del primer año académico.

Resumen de resultados:

- **Clasificación:** GB es el mejor modelo ($F1\text{-macro} = 0.716$, $\text{accuracy} \approx 78\%$). *Matriculado* es la clase más difícil ($\text{recall} \approx 38\%$) por su naturaleza intermedia.
- **Regresión:** GB obtiene $R^2 = 0.54$ y $\text{RMSE} = 0.95$ sin leakage. Añadir el 1.er semestre al perfil multiplica el R^2 por 2.7 ($0.20 \rightarrow 0.54$).

- **Clustering:** $k = 4$ clusters estables con perfiles diferenciados en tasas de abandono (9 %–80 %).

Limitaciones. (i) Correlación $\neq$ causalidad: una nota baja puede ser consecuencia de problemas externos no recogidos en el dataset. (ii) Dataset de una única institución portuguesa, lo que limita la generalización. (iii) *Matriculado* incluye futuros graduados y futuros abandonos, introduciendo ambigüedad estructural irreducible.

References

- [1] V. Realinho et al. *Predicting Student Dropout and Academic Success*. Data, 7(11):146, 2022.
- [2] L. Breiman. *Random Forests*. Machine Learning, 45:5–32, 2001.
- [3] J. H. Friedman. *Greedy Function Approximation: A Gradient Boosting Machine*. Ann. Stat., 29(5):1189–1232, 2001.
- [4] F. Pedregosa et al. *Scikit-learn: Machine Learning in Python*. JMLR, 12:2825–2830, 2011.
- [5] I. T. Jolliffe. *Principal Component Analysis*, 2nd ed. Springer, 2002.