

SQL + Lastfm

Disponible: 8 de febrero de 2025. 18:00

Entrega: 27 de febrero de 2025. 23:55

1 Práctica SQL + Python

1.1 Instrucciones de entrega y consideraciones

A lo largo de este documento se pedirá descargarse un conjunto de datos de Lastfm (música) a partir del cual se deberá procesar y almacenar parte de él en una base de datos relacional. Cada alumno deberá entregar un fichero .zip en el enlace de entrega correspondiente siguiendo el siguiente formato (sin tildes, espacios ni ñes):

```
<nombreAlumno>_<Apellido1>_<Apellido2>_Lastfm_SQL.zip
```

Por ejemplo:

```
Pablo_DelasHeras_Fernandez_Lastfm_SQL.zip
```

En dicho archivo zip se deben entregar los ficheros Python necesarios para el procesamiento y la carga de datos en la base de datos de MySQL. **NO SE DEBERÁ ENTREGAR EL CONJUNTO DE DATOS ORIGINAL DESCARGADO DE LASTFM. SOLO SE DEBERÁ ENTREGAR EL CÓDIGO PYTHON Y EL PDF DEL DIAGRAMA (PRIMERA PARTE) Y EL FICHERO .SQL o PDF PARA LA PARTE DE LAS CONSULTAS (SEGUNDA PARTE).**

IMPORTANTE: dado que esta práctica es algo más compleja que las anteriores, valdrá el doble que el resto de prácticas de la asignatura.

1.2 Pasos previos

Se pide en primer lugar descargarse el conjunto de datos de Lastfm ([disponible aquí](#)) o ([aquí](#)). El segundo enlace será más rápido a la hora de descargar los datos. **Cuidado que son 642Mb.** Dichero conjunto de datos se compone de dos ficheros:

- `userid-timestamp-artid-artname-traid-traname.tsv`: que contiene las escuchas que han realizado los usuarios (`userid`), el momento del tiempo en el que han realizado la escucha (`timestamp`, en formato `%Y-%m-%dT%H:%M:%SZ`), el id del artista (`artid`), el nombre del artista (`artname`), el id de la canción (`traid`) y el nombre de dicha canción (`traname`).
- `userid-profile.tsv`: que contiene información del usuario. Su identificador (`userid`), su género (`gender`), su edad (`age`), el país (`country`) y su fecha de registro (`signup`), en formato `%b %d, %Y`.
 - `%b` es el mes en formato corto. Por ejemplo: Jan, Feb, Dec.
 - `%d` es el día. (Del 1 al 31)
 - `%Y` es el año. Por ejemplo 2021, 2022...

- Todos los campos en ambos ficheros están separados mediante tabulaciones (“\t”).

1.3 Primera parte: Diseño

Una vez descargados los datos, se pide realizar las siguientes tareas (LEED MUY BIEN ESTE APARTADO):

- Diseñar una base de datos relacional a partir de la estructura de los ficheros y almacenar dichos datos en MySQL con la estructura de datos elegida. **La base de datos final debe estar en 3FN.**
- Se puede (de hecho, se recomienda encarecidamente), procesar primero los datos en Python para obtener los ficheros txt necesarios según la estructura elegida para la base de datos. Es obligatorio almacenar la fecha de registro de los usuarios en formato date y la fecha de escucha en formato datetime en SQL. Para procesar las fechas de texto a datetime de Python, puede hacerse uso del siguiente [enlace](#), haciendo uso de la función strptime que transforma un string a un datetime empleando el formato que se desee.
- Debido a que hay un gran número de escuchas en el fichero userid-timestamp-artid-artname-traid-traname.tsv, se pide almacenar **solo el primer millón de escuchas cuyo traid no sea nulo/vacío. Es decir, leed el fichero de escuchas línea a línea e insertad en la base de datos el primer millón de escuchas que no tengan ese valor (traid) a nulo (o vacío). NO ESTARÁ PERMITIDO HACER USO DE PANDAS EN NINGÚN MOMENTO DEL CÓDIGO.**
- Por último, los ids originales de las canciones, y de los artistas **es obligatorio** almacenarlos. También es **obligatorio** crear ids internos propios enteros para identificarlos en nuestra base de datos (es decir, que cada id original de una canción o un artista, tenga un id interno de MySQL que os creéis vosotros que sea un entero). En el caso de los usuarios, también será necesario que os creéis un id interno, si bien no es necesario almacenar el id original. Se recomienda, por ejemplo, que en el caso de los usuarios, que el id original de user_000001 se cambie a 1. **Puede haber canciones y artistas cuyos ids originales coincidan y su nombre no, (es decir, que tengan el mismo id aunque pertenezcan a artistas distintos). Podéis asignarles esas canciones/artistas al primero que haya aparecido, para evitar las repeticiones. Se asume que estos son errores en los datos.**
- Cuidado con los retornos de carro. Cuando se escribe en un fichero de texto en Windows, cuando hay un salto de línea, se incluyen los caracteres de “\r \n”. Deberéis tener cuidado en los ficheros cuando los leáis y los insertéis en las tablas para que los campos no tengan caracteres extraños.

- Se deberá entregar el esquema relacional de la base de datos, normalizada a 3FN, indicando claves primarias de cada una de las tablas, su claves candidatas, y también las claves foráneas.
- Deberás crear un programa en Python que se conecte al servidor de MySQL, cree una base de datos llamada “Lastfm” y cree también las tablas necesarias según tu diseño. Una vez creada las tablas, deberá insertar los datos correspondientes. Se puede partir del siguiente código para crear una base de datos:

```
cursor =conexion_mysql.cursor()
sql = "CREATE DATABASE " +str(nombre_base_datos)
cursor.execute(sql)
sql = "USE " + str(nombre_base_datos)
cursor.execute(sql)
```

Se da también un ejemplo de la tabla de artistas:

```
CREATE TABLE artistas (
    id_artista INT NOT NULL,
    id_lastfm_artista varchar(250),
    nombre_artista varchar(250),
    PRIMARY KEY (id_artista)
);
```

- El código Python desarrollado debe permitir a los profesores ejecutar el programa de forma que cargue todos los datos necesarios sin tener que modificar nada SALVO las rutas de los archivos originales de lastfm. Indica claramente en el código desarrollado donde están las variables a editar para poder cargar los datos. De la misma forma, si necesitáis algún usuario/contraseña para conectaros a MySQL, deberéis indicarlo claramente para que solo haya que editar esas variables y nada más.
- Recuerda que además de la funcionalidad, también es importante el estilo de código y la documentación (serán evaluados en la práctica). Es obligatorio que el programa funcione de manera correcta cuando los profesores lo ejecuten.

Entrega de esta parte: se pide entregar el esquema relacional, el/los ficheros Python necesarios para crear la base de datos y rellenarla con los datos estipulados cumpliendo las restricciones anteriormente mencionadas. En el esquema relacional se permite al estudiante justificar el diseño elegido con un texto. El fichero Python debe llamarse (sin los símbolos de < y >):

```
<nombreAlumno>_<Apellido1>_<Apellido2>_Lastfm_SQL.py
```

Y el fichero del diagrama

`<nombreAlumno>_<Apellido1>_<Apellido2>_Lastfm_Diagrama.jpg (o pdf)`

1.4 Segunda parte: consultas

Una vez se tengan cargados todos los datos, se pide realizar las siguientes consultas:

1. Obtener la media de edad de los usuarios que han escuchado a “Coldplay”.
2. Obtener el número total de hombres que han escuchado a “Janet Jackson” o “The Clash”.
3. Obtener el número total de usuarios que o bien son de España (Spain) o bien han escuchado a ‘Red Hot Chili Peppers’.
4. Obtener el promedio de escuchas por usuario para aquellos que tienen entre 19 y 21 años. Si un usuario no ha escuchado nada, igualmente debe ser tenido en cuenta.
5. Obtener los usuarios cuyo número total de escuchas superan a la media del total de escuchas de los usuarios.
6. Número total de escuchas por país.
7. Obtener las 15 canciones que tienen un mayor número de escuchas de usuarios distintos (muestra el nombre de la canción y el número de usuarios distintos que la han escuchado).
8. Obtener el porcentaje de escuchas del total que han realizado los usuarios cuya edad supera la media de edad de todos los usuarios. Para esta consulta, ignora a aquellos usuarios cuya edad es 0 o nula.

Entrega de esta parte: se pide entregar un pdf o un fichero .sql dando respuesta a cada una de las consultas requeridas que deberá incluirse en el zip de entrega. El fichero pdf/sql debe llamarse de esta forma:

`<nombreAlumno>_<Apellido1>_<Apellido2>_Lastfm_consultas.pdf (o sql)`

2 Opcional. Web scrapping.

En este apartado se va a hacer uso de Web scraping para extraer datos de una página web para que posteriormente sean cargados en tablas de una base de datos relacional. Para ello, se va a hacer uso de Python y podéis hacer uso de cualquier librería que queráis para poder hacer Web scrapping. Un ejemplo de librería que podéis utilizar es BeautifulSoup 4, que deberá ser instalada en caso de querer utilizarla. Tenéis en este enlace la descripción de cómo instalar

la librería [enlace](#). BeautifulSoup 4, se encarga de extraer la información de archivos en formato html, pero para obtener dichos archivos necesitamos la función `urlopen()` de otra librería: `urllib.request`.

3 Funciones a emplear (en caso de utilizar BeautifulSoup)

En esta sección se explican algunas funciones importantes que pueden emplearse para poder extraer los datos de una página web empleando la librería mencionada antes.

`urlopen(String url):`

Para importar esta función usamos: `from urllib.request import urlopen`. La función `urlopen()` recibe como parámetro la url de la página web donde está la información que vamos a extraer. La url debe ser un String. Devuelve un objeto que contiene el enlace o conexión a la página web, que leeremos con el método `read()`. Finalmente, cerraremos la conexión como si de un fichero se tratase con el método `close()`.

`BeautifulSoup(String documentoHTML, String parserLibrary):`

Para importar esta función usaremos: `from bs4 import BeautifulSoup`. La función `BeautifulSoup()` recibe como parámetros dos elementos:

- `documentoHTML`: Le pasaremos la página html que extraeremos con el método `read()`.
- `parserLibrary`: utilizaremos el formato “html.parser”.

Dicha función devuelve un objeto tipo soup, que consiste en la información HTML de la página web organizada jerárquicamente para facilitar su manejo en Python. Usaremos el método `findAll()` para acceder a la parte del documento que nos interesa.

4 Información a extraer

Una vez elegida la página web y la información a extraer, es necesario analizar la estructura html de la página. Algunas herramientas que facilitan este proceso están disponibles en los exploradores al hacer click derecho en nuestra página de interés, como “Ver código fuente de la página” o “Inspeccionar elemento” (también F12). En el caso de la tabla con los ganadores de Roland Garros, se muestra en la Figura 1:

de csv, pero el objetivo es obtener un fichero de texto conteniendo los atributos de la tabla. Una vez que habéis creado el archivo csv, habrá que continuar el código Python creando una base de datos con una tabla y finalmente cargar dichos datos en la base de datos. El archivo Python a entregar deberá llamarse

<code>nombreAlumno>_<Apellido1>_<Apellido2>_WebScraping.py</code>
--

Y deberá incluirse en el zip de entrega.